# Specialisti a lettura condivisa: prova di sviluppo su CUAD

Giro del 15/10/2026 su AMD MI300X, dalle 09:41 alle 10:36 (ora italiana). Qwen3-14B in bf16, revisione `40c0698`, telepatia con 0 passi latenti, codice `f2dc1b2` sul branch `feat/116-specialisti`. Issue #116, soluzione 1.

> **In breve.** Su 40 contratti CUAD mai usati, tre specialisti che lavorano sulla memoria di una sola lettura battono l'agente solo di **+3,7 punti di F1** (intervallo al 95% da –0,9 a +8,4), con la stessa spesa di token generati e tempo. Il guadagno viene dalla **divisione del lavoro**: gli stessi specialisti che rileggono il contratto a testo arrivano quasi allo stesso punto (+2,8). La telepatia dà quella qualità leggendo il contratto **una volta invece di tre** (–60% di token letti). **È una prova esplorativa, non pre-registrata: niente è dimostrato**, gli intervalli comprendono lo zero.

## Come funziona

- **Agente solo:** un Qwen legge il contratto e scrive il verdetto su tutte le 19 categorie (la configurazione `solo` dell'eval).
- **Specialisti in telepatia:** un lettore legge il contratto una volta, con le 19 categorie in testa come l'agente solo, e non scrive niente. La memoria della sua lettura (cache KV, 0 passi latenti) si copia a tre specialisti: legale (7 categorie), finanza (4), rischio (8). Ognuno scrive il JSON solo per le sue categorie, senza rileggere il contratto. Le risposte si uniscono: ogni categoria ha un solo responsabile, non c'è voto.
- **Specialisti che rileggono:** gli stessi tre specialisti, ma ognuno rilegge tutto il contratto a testo. È il controllo: stessa divisione del lavoro, senza telepatia.

## Dati

40 contratti CUAD dello split **train**, mai usati da test e replica (che usano lo split test), sotto i 24.000 token, esclusi i 5 di sviluppo dell'eval, estratti con seme `116-sviluppo`. 760 coppie contratto-categoria (183 da segnalare), risposte giuste calcolate come in `prepara.py`. Un verdetto non valido conta «no» su tutte le sue categorie, come nell'eval.

## Risultati

| 40 contratti | F1 | Precisione | Richiamo | MCC | Verdetti validi | Token letti | Token generati | Secondi |
|---|---|---|---|---|---|---|---|---|
| Agente solo | 72,2 | 75,1 | 69,4 | 0,64 | 39/40 | 9.412 | 552 | 27 |
| **Specialisti in telepatia** | **75,9** | 75,3 | **76,5** | 0,68 | 40/40 | 10.733 | 536 | 27 |
| Specialisti che rileggono | 75,0 | 78,1 | 72,1 | 0,68 | 40/40 | 26.521 | 545 | 27 |

Base «sempre sì»: 38,8. Token per contratto. Differenze di F1 con bootstrap appaiato sui 40 contratti (10.000 ricampionamenti):

| Confronto | Differenza | Intervallo al 95% |
|---|---|---|
| Specialisti in telepatia – agente solo | **+3,7** | da –0,9 a +8,4 |
| Specialisti che rileggono – agente solo | +2,8 | da –1,3 a +7,2 |
| Specialisti in telepatia – specialisti che rileggono | +0,9 | da –3,3 a +5,4 |

## Criterio deciso prima dei numeri

Da #116: «promettente» se specialisti – agente solo ≥ +3 punti di F1 e token ≤ 2× quelli dell'agente solo.

- ☑ +3,7 ≥ +3
- ☑ token letti 1,14× e generati 0,97× quelli dell'agente solo

**Esito: promettente.** Si passa al test pre-registrato.

## Cosa si può dire e cosa no

- **Si vede:** dividere le 19 categorie fra tre specialisti fa trovare più clausole: 140 su 183 invece di 127 (richiamo da 69,4 a 76,5), con 4 falsi allarmi in più (46 contro 42), quindi la stessa precisione.
- **Si vede:** la telepatia non perde niente rispetto agli specialisti che rileggono (+0,9) e legge il 60% di token in meno. È la stessa storia del test e della replica: qualità pari al testo, costo molto più basso.
- **Non si può dire** che il vantaggio sull'agente solo è dimostrato: con 40 contratti l'intervallo comprende lo zero, e i numeri sono stati guardati senza pre-registrazione.
- **Non si può dire** che la telepatia «ragiona meglio»: il guadagno è della divisione del lavoro, la telepatia lo rende economico.
- **Tempo uguale (27 s) per tutte e tre:** confermato anche dall'orologio, 18 minuti per configurazione. Sulla MI300X leggere 9-26 mila token costa pochi secondi; il tempo va quasi tutto nello scrivere la risposta.

## Prossimo passo

Test pre-registrato su 150-200 contratti CUAD train nuovi (esclusi questi 40), specialisti in telepatia contro agente solo, con gli specialisti che rileggono come controllo, il 16-17/10. Con quel numero di contratti un vantaggio di 3-4 punti diventa misurabile.

## Risultati grezzi

`~/hackathon/risultati-mi300x/sviluppo-116/` sul Mac di chi ha lanciato il giro: i tre `.jsonl`, `contratti.json` (i 40 contratti), `giuste.json`, `prova-116.log` e `confronta116.py` (lo script del confronto).