Eval del Consiglio: rapporto del test pre-registrato

Test del 13/10/2026 su AMD MI300X · Qwen3-14B in bf16, telepatia con 0 passi latenti · pre-registrazione e codice al commit `d3c1ec1` (ramo `feat/62-eval`) · issue #62

> **In breve.** Su CUAD, il benchmark principale, il Consiglio in telepatia soddisfa tutte e tre le condizioni del G4: F1 72,5 contro 70,7 del Consiglio a testo, **75% di token generati in meno**, 54 secondi per contratto invece di 144. Il giudizio pre-registrato è **«risultati compatibili»**, non «dimostrato»: con 20 contratti l'intervallo al 95% della differenza va da −6,9 a +9,6 punti, quindi non esclude una perdita di oltre 3 punti. Su CLAUDETTE la telepatia batte il testo in modo netto (+6,8 punti, intervallo da +3,2 a +10,4). Un **agente solo** che legge tutto il contratto è alla pari o un po' davanti, e costa meno.
>
> *«Gli agenti si passano la memoria di ciò che hanno letto invece di riscriverlo: stessa qualità, 75% di token in meno, quasi 3 volte più veloce.»*

1. Cosa abbiamo misurato

Per ogni contratto il sistema dice quali tipi di clausola contiene (sì/no per categoria), con una citazione come prova. Le risposte si confrontano con quelle annotate da esperti. Ogni coppia (contratto, categoria) è una **trovata**, una **mancata**, un **falso allarme** o un giusto silenzio. Da lì:

- **Precisione**: delle clausole segnalate, quante erano vere (misura i falsi allarmi).
- **Richiamo**: delle clausole vere, quante ne ha trovate (misura quelle sfuggite).
- **F1**: media armonica di precisione e richiamo, da 0 a 100. È il voto principale.
- **MCC**: da −1 a 1, conta anche i «no» giusti. Serve quando quasi tutte le risposte giuste sono uguali (CLAUDETTE).

Tutti i sistemi usano lo **stesso modello** (Qwen3-14B) sulla stessa GPU. Cambia solo l'organizzazione del lavoro:

Configurazione	Come lavora
Agente solo	Un modello legge tutto il contratto e decide.
Voto fra 4	Quattro esperti leggono tutto, ognuno da solo; vince la maggioranza.
Consiglio a testo	Tre esperti leggono una sezione ciascuno e scrivono un'analisi; il relatore decide leggendo le analisi.
Consiglio in telepatia	**Come a testo, ma gli esperti passano al relatore la memoria di lettura invece di scrivere.**
Contratto scambiato	*Il Consiglio legge un contratto e lo si valuta con le risposte di un altro: deve crollare.*

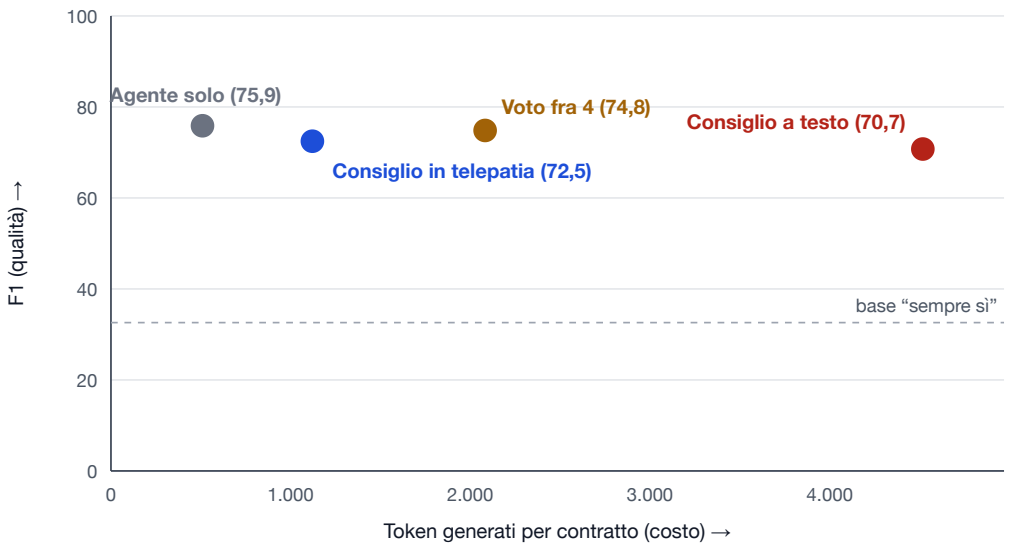
Spiegazione completa per il team: `consiglio/COME-MISURIAMO.md` su `main`. Regole ufficiali: `consiglio/PREREGISTRAZIONE.md` su `feat/62-eval`.

2. CUAD: il benchmark principale

20 contratti commerciali reali, 19 tipi di clausola: 380 domande sì/no per configurazione.

Configurazione	F1	Precisione	Richiamo	MCC	Mancate	Falsi allarmi	Verdetti validi	Token generati per contratto	Secondi per contratto
Agente solo	**75,9**	77,5	74,3	0,70	19	16	20/20	509	23
Voto fra 4	**74,8**	75,3	74,3	0,69	19	18	20/20	2.082	94
Consiglio a testo	**70,7**	71,2	70,3	0,64	22	21	20/20	4.517	144
Consiglio in telepatia	**72,5**	**78,1**	**67,6**	**0,67**	**24**	**14**	**20/20**	**1.121**	**54**
Contratto scambiato (controllo)	***34,8***	*37,5*	*32,4*	*0,20*	*50*	*40*	*20/20*	*1.121*	*53*

Base “sempre sì” (un sistema finto che risponde sempre sì): F1 32,6.



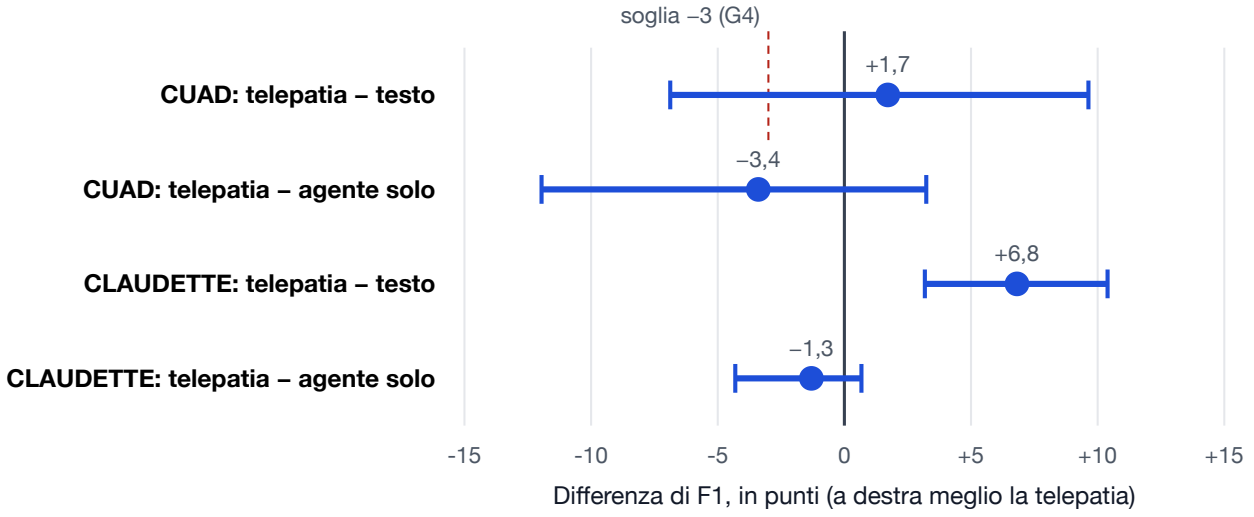
CUAD, test: qualità contro costo. In alto a sinistra è meglio: più F1 con meno token.

Il criterio G4 (pre-registrato)

- ✅ F1 telepatia ≥ F1 testo − 3 punti: +1,7 punti
- ✅ Token generati almeno −50%: −75%
- ✅ La telepatia non è più lenta del testo: 54 s contro 144 s

> **Perché «compatibili» e non «dimostrato».** Per dire «non perde, dimostrato» anche il limite inferiore dell'intervallo al 95% doveva stare sopra −3. È a −6,9: con 20 contratti l'incertezza è troppo larga. Per questo è prevista una **replica su 50 contratti CUAD nuovi** (#118), decisa prima di vedere questi intervalli.

3. Quanto sono sicure le differenze



Il punto è la differenza misurata; la barra è l'intervallo al 95% (bootstrap appaiato sui 20 contratti, 10.000 ripetizioni). Se la barra attraversa lo 0, la differenza non è sicura.

- **CUAD, telepatia contro testo**: pari (barra larga, attraversa lo 0).
- **CUAD, telepatia contro agente solo**: l'agente solo è avanti di 3,4 punti, ma la barra attraversa lo 0: non è una differenza sicura.
- **CLAUDETTE, telepatia contro testo**: la telepatia è **meglio in modo netto** (barra tutta a destra dello 0).
- **CLAUDETTE, telepatia contro agente solo**: pari.

4. CLAUDETTE: termini di servizio online

20 termini di servizio, 9 tipi di clausola potenzialmente abusiva. Qui quasi tutte le risposte giuste sono «sì» (79%): un sistema che dice sempre sì prende già F1 88,5. Il voto da guardare è l'**MCC** (il sistema finto prende 0).

Configurazione	F1	Precisione	Richiamo	MCC	Mancate	Falsi allarmi	Verdetti validi	Token generati per contratto	Secondi per contratto
Agente solo	93,3	89,7	97,2	**0,63**	4	16	20/20	757	39
Voto fra 4	93,3	89,7	97,2	**0,63**	4	16	20/20	3.006	155
Consiglio a testo	85,2	93,3	78,3	**0,49**	31	8	20/20	3.742	143
Consiglio in telepatia	**92,0**	**91,7**	**92,3**	0,60	**11**	**12**	**20/20**	**1.233**	**67**
Contratto scambiato (controllo)	*80,8*	*80,6*	*81,1*	***0,05***	*27*	*28*	*20/20*	*1.233*	*67*

Base “sempre sì” (un sistema finto che risponde sempre sì): F1 88,5.

5. Set dimostrativo: i 4 contratti italiani della demo

Solo numeri aggregati: i contratti restano privati. Con 4 contratti è un indizio, non una prova.

Configurazione	F1	Precisione	Richiamo	MCC	Mancate	Falsi allarmi	Verdetti validi	Token generati per contratto	Secondi per contratto
Agente solo	**90,9**	92,6	89,3	0,86	3	2	4/4	704	31
Voto fra 4	**90,9**	92,6	89,3	0,86	3	2	4/4	2.875	126
Consiglio a testo	**94,3**	100,0	89,3	0,92	3	0	4/4	4.424	139
Consiglio in telepatia	**98,2**	**96,6**	**100,0**	**0,97**	**0**	**1**	**4/4**	**1.438**	**67**
Contratto scambiato (controllo)	***31,6***	*31,0*	*32,1*	*-0,09*	*19*	*20*	*4/4*	*1.438*	*65*

Base “sempre sì” (un sistema finto che risponde sempre sì): F1 53,8.

6. ContractNLI: non valido come misura

> Tutte le configurazioni hanno **MCC negativo** (da -0,32 a -0,20) e F1 sotto la base «sempre sì» (20,1), **compreso il contratto scambiato**. Il compito chiede se l'accordo *contraddice* un'ipotesi; il modello risponde invece se la clausola *c'è*, perché nel formato della risposta ogni ipotesi ha un nome breve («Return of confidential information») dentro un campo «segnalare». È un difetto di come abbiamo posto la domanda, uguale per tutti i sistemi: i numeri di ContractNLI non dicono niente su chi va meglio e non vanno citati.

7. I controlli

- **Contratto scambiato**: crolla dove deve. CUAD da 72,5 a 34,8 (circa la base «sempre sì»); CLAUDETTE MCC da 0,60 a 0,05; set dimostrativo da 98,2 a 31,6. Il sistema legge davvero il contratto.
- **Verdetti validi**: 100% in tutte le configurazioni e su tutti i benchmark.
- **Analisi a testo troncate**: 0 su 60 su CUAD (il tetto è stato alzato a 2.048 token prima del test: a 512 le troncava tutte).
- **Risposte giuste**: rigenerate da zero dalle fonti originali prima del test, identiche a quelle usate.

8. Cosa ne ricaviamo

- **In una pipeline a più agenti, la telepatia è il modo più efficiente di farli comunicare**: stessa qualità del testo su CUAD, meglio su CLAUDETTE, con il 67-75% di token in meno e meno della metà del tempo.
- **Per trovare clausole un agente solo basta**: è alla pari o un po' avanti e costa meno. Il valore del Consiglio non è nell'F1, ma in ciò che l'F1 non misura: note per ruolo, dissensi visibili, catena dei

messaggi firmata. Come far vincere un gruppo è in #116.
- **La GPU ha margine**: un contratto alla volta usa circa il 16% della memoria della MI300X. Più contratti in parallelo: #117.

9. Limiti

- 20 contratti per benchmark: differenze di 2-3 punti non si distinguono dal caso. Da qui la replica su 50 (#118).
- Contratti sotto i 24.000 token: sui documenti molto lunghi il test non dice niente.
- Il prompt del relatore dice «non hai letto il contratto» anche in telepatia, dove lavora sulla memoria della lettura.
- Il taglio per ruolo manda il 46% delle clausole CUAD a un esperto che non le cura: penalizza soprattutto il testo.

10. Deviazioni dalla pre-registrazione

1. Congelata senza la rilettura del team delle definizioni operative (da fare dopo).
2. Il controllo fp32 contro bf16 di G1 usa il backend math di PyTorch per il riferimento fp32 (in fp32 i kernel veloci non partivano).
3. Riaperta e ricongelata il 13/10, **prima** del test, dopo una revisione indipendente di metriche, risposte giuste ed equità: tetto delle analisi a testo da 512 a 2.048 token, confronto con l'agente solo, «dimostrato» solo su CUAD, analisi per lunghezza.

11. Prossimi passi

- Controllo a mano alla cieca sui 4 contratti italiani (fogli pronti, privati).
- Replica su 50 contratti CUAD nuovi (#118).
- Scelta fra Sportello e Consiglio: G4 del 16/10/2026 alle 12:00.

Macchina: AMD Developer Cloud, 1× MI300X 192 GB, ROCm 7.2; container `vllm/vllm-openai-rocm:v0.30.0`, torch 2.12, transformers 4.57.6; Qwen3-14B revisione `40c0698`; decodifica greedy, batch 1. Test dalle 11:05 alle 18:30 (ora italiana). Generato da `numeri.json` del rapporto: nessun numero ricopiato a mano.